

Apresentação: Processo de ETL – Projeto RAIS: Demanda Setorial e Especializações em TI

Bom dia a todos! Meu nome é Marcio, e hoje vou apresentar como estruturamos a etapa de ETL — Extração, Transformação e Carga — do nosso projeto de análise da empregabilidade em TI com base nos dados da RAIS, no contexto da residência em análise de dados da PUC-Rio e ECOA.

1. Objetivo da ETL

Nosso objetivo com essa etapa foi preparar uma base sólida, confiável e analiticamente rica para responder perguntas como:

- Quais setores mais contratam profissionais de TI?
- Quais especializações estão em alta?
- Como o porte da empresa e a natureza jurídica influenciam a remuneração e a demanda?

Partimos de um dataset bruto com mais de 2 milhões de registros, abrangendo o período de 2019 a 2024.

2. Etapas do Processo de KDD aplicadas ao projeto

2.1 Seleção de Dados

Selecionamos registros da RAIS relacionados a ocupações de tecnologia da informação.

Aplicamos filtros por CBO e por período (2019–2024).

2.1.1 Redução Horizontal

Reduzimos o número de linhas ao manter apenas profissionais de TI.

2.1.2 Redução Vertical (Seleção de Atributos)

Mantivemos apenas os campos relevantes: sexo, idade, raça, grau de instrução, vínculo, salário, CNAE, CBO, município, natureza jurídica, porte da empresa.

2.2 Pré-processamento

Tratamos valores nulos e inconsistentes.

Padronizamos nomes de colunas e removemos duplicatas.

Identificamos e visualizamos outliers salariais.

2.3 Transformação

Transformamos variáveis numéricas em categóricas legíveis (ex: sexo = 1 → masculino).

Criamos a coluna `faixa_salarial` com discretização baseada no salário mínimo.

Realizamos joins com dicionários externos para enriquecer os dados.

2.4 Mineração de Dados

Aplicamos agrupamentos, contagens e médias para gerar tabelas derivadas.

Investigamos padrões salariais por subsetor, porte da empresa e função.

2.5 Interpretação e Avaliação

Visualizamos os dados com heatmaps, boxplots e gráficos de barras.

Avaliamos os padrões encontrados com base nas perguntas-chave do projeto.

3. Tarefas do Processo de KDD

3.1 Tarefas de Amostragem

Criamos sub-datasets específicos, como os 30 maiores salários, para análise de extremos.

3.2 Tarefas Descritivas

Geramos estatísticas como média, mediana, desvio padrão e amplitude salarial.

Produzimos gráficos que mostram a distribuição por subsetor, porte da empresa e faixa salarial.

3.3 Tarefas de Prognóstico

Embora o foco tenha sido descritivo, os dados estão preparados para futuras análises preditivas, como projeções de demanda por especializações ou evolução salarial.

4. Extração dos Dados

A extração foi feita a partir de um arquivo CSV armazenado no Google Drive, contendo os dados da RAIS já filtrados para ocupações relacionadas à tecnologia da informação. Utilizamos o Google Colab como ambiente de desenvolvimento, o que facilitou a integração com o Drive e a colaboração entre os membros da equipe.

5. Transformações Realizadas

A transformação foi a etapa mais extensa e crítica do processo. Os principais pontos foram:

a) Mapeamento de Variáveis Categóricas

Convertendo códigos numéricos em valores legíveis:

sexo → masculino, feminino, ignorado

raça_cor → branca, parda, preta, etc.

grau_instrucao → médio completo, superior completo, mestrado, etc.

tamanho_estabelecimento → faixas como “Até 4”, “De 100 a 249”, “1000 ou mais”

b) Criação da Coluna faixa_salarial Com base no salário mínimo de R\$ 1.518,00, criamos 12 faixas salariais, de “Até 0,5 salários mínimos” até “Mais de 20 salários mínimos”. Isso permitiu lidar com a alta dispersão dos salários e facilitar comparações entre setores e portes de empresa.

c) Tratamento de Outliers

Identificamos salários que variavam de R\$ 0 até mais de R\$ 1 milhão. Usamos describe(), nlargest() e boxplots para visualizar e entender esses extremos. Isso nos ajudou a decidir como tratar valores atípicos nas análises posteriores.

6. Enriquecimento com Dicionários

Para tornar os dados mais interpretáveis, realizamos joins com três dicionários externos:

a) Natureza Jurídica Associamos os códigos a descrições como “empresa privada”, “administração pública”, “cooperativa”, etc.

b) Municípios

Adicionamos o nome do município ao código `id_municipio`, essencial para análises geográficas.

c) Profissões de TI Cruzamos com uma lista de ocupações específicas da área de tecnologia, como analistas, técnicos, engenheiros e administradores de TI. Isso nos permitiu isolar e analisar apenas os profissionais de TI dentro da RAIS.

7. Criação de Sub-datasets

Para facilitar análises segmentadas e visualizações específicas, criamos diversos sub-datasets derivados do `df_principal2`:

a) Filtragem por Profissões de TI Criamos o `df_ti`, contendo apenas os registros de profissionais da área de tecnologia, com base na coluna `descricao_familia`.

b) Tabelas Derivadas para Visualização

Geramos sub-datasets com agrupamentos e métricas específicas:

```
df_subsetor_por_natureza_juridica  
df_descricao_por_natureza_juridica  
df_subsetor_uf  
df_descricao_uf  
df_descricao_subsetor
```

Essas tabelas foram fundamentais para alimentar os dashboards no Looker.

c) Sub-dataset de Outliers

Criamos um dataset com os 30 maiores salários (outliers_remuneracao_media) para investigar valores extremos.

d) Sub-dataset por Faixa Salarial Geramos crosstabs e heatmaps cruzando salário com porte da empresa e subsetor IBGE, como:

```
freq_table_salario_x_estabelecimento  
freq_crosstab_subsetor_x_faixa_salarial
```

8. Visualizações e Métricas

Com os dados prontos, criamos:

Heatmaps cruzando faixa salarial × porte da empresa

Gráficos de barras com frequência por subsetor

Boxplots para distribuição salarial

Crosstabs para entender a distribuição de profissionais por faixa e setor

Essas visualizações revelaram padrões importantes, como:

Empresas maiores tendem a pagar salários mais altos

Subsetores como instituições financeiras e administração pública concentram os maiores salários

A maior parte dos profissionais de TI está concentrada em faixas entre 1,5 e 4 salários mínimos

9. Exportação e Disponibilização

Por fim, salvamos o DataFrame final como `df_processed.csv`, pronto para ser usado em análises exploratórias, dashboards e relatórios.

Conclusão

A etapa de ETL foi essencial para garantir a qualidade, consistência e profundidade das análises. Ela nos permitiu transformar um dataset bruto e complexo em uma base analítica

rica, capaz de responder às perguntas estratégicas do projeto com clareza e precisão.