

Análise de Demanda Setorial e Especialização no Mercado de TI

Fonte de Dados: RAIS (Relação Anual de Informações Sociais) - Microdados

Responsável Técnico: Felipe Rangel, Márcio de Oliveira e Matheus Rosetti

Estágio 1: ETL, Enriquecimento e Normalização Dimensional (*Anexo 1*)

A base bruta da RAIS é composta majoritariamente por códigos categóricos (inteiros) que dificultam a leitura analítica direta. A primeira etapa do processamento consistiu na **desnormalização controlada** dos dados para enriquecimento semântico.

- **Técnica de Mapeamento (Mapping):** Utilizamos dicionários de "De-Para" via função `pd.map()` para traduzir variáveis de baixa cardinalidade, como `sexo`, `raca_cor` e `grau_instrucao`. Isso otimiza o processamento em memória comparado a múltiplos joins físicos.
- **Modelagem Dimensional (Star Schema Híbrido):** Para dimensões de alta cardinalidade ou que exigem filtros hierárquicos, aplicamos operações de `Left Join` com tabelas dimensionais auxiliares.
 - **Dimensão Geográfica:** Enriquecimento via `id_municipio` para obtenção de nomes normalizados.
 - **Dimensão Ocupacional (CBO):** Cruzamento com a tabela `profissoes-ti` para trazer descrições, famílias e subgrupos da CBO 2002.
 - **Dimensão Jurídica:** Cruzamento com `id_natureza_juridica` para classificar as empresas contratantes.

Estágio 2: EDA, Filtragem de Domínio e Engenharia de Atributos (*Anexo 2*)

Após a normalização, aplicamos um filtro de escopo estrito para isolar o mercado de Tecnologia da Informação.

- **Filtragem por Família Ocupacional:** Foi definida uma *query* contendo as descrições de famílias CBO pertinentes ao estudo, incluindo "Diretores de TI", "Engenheiros de Computação", "Analistas de TI" e "Técnicos de Desenvolvimento", descartando ruídos de outras profissões.
- **Criação de Faixas Salariais (Binning):** Para facilitar a análise de distribuição de renda, aplicamos a discretização da variável contínua `valor_remuneracao_media`. Utilizamos o método `pd.cut` tendo como base o salário mínimo de referência (R\$ 1.518,00), criando a variável categórica `faixa_salarial`.

4. Estágio 3: Agregação e Otimização para Visualização (Anexo 3)

Para garantir a performance do Dashboard (Looker Studio) e evitar latência em tempo de execução, optou-se por não carregar os microdados brutos na camada de visualização. Em vez disso, criamos **Data Marts** agregados.

O pipeline se ramifica em visões estratégicas consolidadas:

1. **Visão por Natureza Jurídica:** Agrupamento dos dados por `ano`, `tamanho_estabelecimento` e `natureza_juridica` para contagem de frequência (`count_values`) e cálculo de média salarial.
2. **Visão Geográfica (UF):** Agrupamento por `sigla_uf` e `subsetor` para espacialização da demanda.

Essa estratégia reduziu a granularidade do nível "Vínculo Empregatício" para o nível "Setor/Região", reduzindo drasticamente o volume de linhas sem perda de valor analítico para as métricas macroeconômicas.

Perfeito. As imagens ilustram claramente o desafio estatístico que enfrentamos: o **desbalanceamento de classes** (histograma) e a **dispersão salarial** (heatmap).

5. Engenharia Analítica e Definição de KPIs

Após a etapa de ETL, a base de dados apresentou desafios estatísticos inerentes à natureza do mercado brasileiro, exigindo tratamentos específicos antes da aplicação das métricas de negócio.

5.1. Mitigação de Viés e Desbalanceamento de Classes

A análise exploratória revelou um severo desbalanceamento na distribuição de trabalhadores por subsetor do IBGE (vide *Anexo 5 - Histograma de Frequência*). O subsetor "Comércio e administração de imóveis/Serviços Técnicos" apresentou volume aproximadamente **5x superior** ao segundo maior cluster.

- **Risco Identificado:** A agregação simples dos dados geraria um viés (bias) onde as tendências deste grande setor mascarariam o comportamento de nichos específicos de TI (como Indústria de Transformação ou Financeiro).
- **Estratégia de Correção:** Implementamos uma análise estratificada combinada com a técnica de **Binning Salarial** (vide *Anexo 6 - Heatmap de Distribuição*). Ao segmentar a remuneração em faixas discretas (ex: "10 a 15 Salários Mínimos"), conseguimos normalizar a comparação entre setores heterogêneos, permitindo identificar onde estão concentrados os especialistas seniores, independentemente do volume total do setor.

5.2. Métrica 1: Saldo de Demanda Líquida (Net Demand)

Para mensurar a vitalidade do mercado além do "estoque" de profissionais, desenvolvemos o algoritmo de **Saldo de Vagas**.

Fórmula Saldo de Vagas

$$SV = Ad - Des$$

Onde:

- *SV = Saldo de Admissões*
- *Des = Total de Desligamentos*

- **Lógica Vetorizada:** Diferente da contagem simples de ativos, esta métrica processa os vetores de admissão e desligamento mês a mês.
- **Aplicação:** Esta métrica permite isolar o "Turnover" (alta rotatividade) do "Crescimento Real" (novas posições abertas), sendo crucial para validar a hipótese de substituição de funções operacionais por cargos estratégicos.

5.3. Métrica 2: Valorização Salarial Real (CAGR) (Anexo 4)


Para avaliar a evolução da remuneração e a "premiumização" de carreiras específicas, optamos pelo cálculo do **CAGR (Compound Annual Growth Rate)** aplicado sobre a mediana salarial, conforme detalhado no diagrama lógico em anexo.

$$CAGR = \left(\frac{Valor\ final}{Valor\ Inicial} \right)^{\frac{1}{n}} - 1$$

- **Por que Mediana e não Média?** A presença de *outliers* validados (C-Levels com salários > R\$ 200k) distorcia a média aritmética. A mediana provou-se uma medida de tendência central mais robusta para representar o "salário típico" do profissional de TI.


O resultado percentual permitiu classificar as carreiras em quadrantes de "Em Desvalorização" (CAGR negativo, ex: DBA) vs. "Em Ascensão Acelerada" (CAGR > IPCA, ex: Arquiteto de Soluções).

ANEXO - 1




(ETL 1)

ANEXO - 2




(ETL 2)

ANEXO - 3




(EDA 3)

ANEXO - 4




(Fluxograma cálculo CAGR)

ANEXO - 5



(Histograma distribuição de trabalhadores por subsector IBGE)

ANEXO - 6



(Heatmap entre subsetor ibge e faixas salariais)